물리적 계층 아티팩트 분석 및 하이브리드 머신러닝 기반 차세대 **SIM Box** 탐지 시스템 구축 프로젝트 계획서

1. 프로젝트 개요

1.1 프로젝트 명칭

물리적 계층 아티팩트 분석 및 하이브리드 머신러닝 기반 차세대 **SIM Box** 탐지 시스템 구축

*(*부제*: RTP* 패킷의 시간적 특성 분석을 통한 *VoIP* 우회 사기 탐지 프로토타입 개발*)*

1.2 배경 및 필요성

통신 사기의 고도화와 **SIM Box**의 위협 현대 통신 네트워크 환경에서 사기(Fraud) 수법은 단순한 기술적 허점을 이용하는 단계를 넘어, 네트워크의 구조적 특성을 악용하는 형태로 진화하고 있습니다. 특히 '인터커넥트 바이패스(Interconnect Bypass)' 또는 'SIM Box' 사기는 전 세계 통신 사업자에게 연간 약 450억 달러(한화 약 60조 원)에 달하는 막대한 손실을 입히고 있는 가장 심각한 위협 중 하나입니다.[1]

SIM Box는 수십에서 수백 개의 SIM 카드를 장착할 수 있는 GSM/VoIP 게이트웨이 장비입니다. 사기범들은 국제 전화 트래픽을 인터넷(VoIP)을 통해 착신 국가의 SIM Box로 전송한 뒤, 해당 장비에서 현지 SIM 카드를 이용해 일반적인 국내 통화인 것처럼 위장하여 발신합니다. 이 과정에서 통신사가 정당하게 수취해야 할 국제 전화 접속료(Termination Fee)가 탈루되며, 이는 통신사의 수익 악화뿐만 아니라 국가적인 세수 손실로 이어집니다.[2]

기존 탐지 기술의 한계와 학생 주도 연구의 필요성 기존의 탐지 시스템은 주로 CDR(Call Detail Record, 통화 상세 기록) 분석에 의존해 왔습니다. "한 번호로 하루에 100통 이상의 전화를 걸면 사기"라는 식의 규칙 기반(Rule-based) 탐지는 사기범들이 도입한 '인간 행동 모사(HBS, Human Behavior Simulation)' 기술에 의해 무력화되고 있습니다. HBS 기술은 SIM Box가 마치 실제 사람처럼 이동(기지국 변경), SMS 발송, 불규칙한 통화 시간 등을 수행하도록 프로그래밍하여 CDR 기반의 패턴 분석을 회피합니다.[1]

이러한 상황에서 본 프로젝트는 **"물리적 아티팩트(Physical Artifacts)는 조작할 수 없다"**는 가설에 기반합니다. 저성능의 SIM Box 하드웨어와 불안정한 사설 인터넷망을 경유하는 과정에서 발생하는 음성 데이터 패킷(RTP)의 지연(Latency)과 지터(Jitter)는 소프트웨어적으로 완벽하게 은폐하기 어렵습니다.[1]

본 프로젝트는 학부생 수준의 팀이 접근하기 어려운 통신사의 코어 데이터 접근이나 고가의 전용 장비 없이, **오픈 소스 소프트웨어(Python, Scapy)**와 **네트워크 시뮬레이션 기법(Linux tc-netem)**을 활용하여 이러한 물리적 특징을 분석하고 탐지하는 모델을 구축하는

것을 목표로 합니다. 이는 사이버 보안, 네트워크 엔지니어링, 데이터 사이언스가 융합된 주제로, 학생들이 실무적인 통신 보안 기술을 습득할 수 있는 최적의 캡스톤 디자인 주제입니다.[6]

1.3 기대 효과

기술적 역량 강화 및 교육적 효과

- 네트워크 프로토콜의 심층 이해: SIP(신호)와 RTP(미디어) 프로토콜의 구조를 분석하고, 패킷 캡처 도구(Wireshark, Scapy)를 활용하여 네트워크 3~7계층을 아우르는 실무 지식을 습득합니다.[8]
- 머신러닝 파이프라인의 전 과정 경험: 단순히 정제된 데이터셋을 학습시키는 것을 넘어, 원시 패킷 데이터(Raw Packet)로부터 유의미한 특징(Feature)을 추출하고, 불균형 데이터(Imbalanced Data) 문제를 해결하며 모델을 최적화하는 MLOps의 기초를 다집니다.[7]

사회적 및 경제적 파급 효과

- 저비용 보안 솔루션의 가능성 제시: 수억 원대의 상용 장비 없이도 범용 하드웨어와 오픈 소스 기술만으로 유의미한 수준의 사기 탐지가 가능함을 증명함으로써, 중소형 별정 통신사(MVNO)나 VoIP 사업자를 위한 경제적인 보안 대안을 제시합니다.[1]
- 프라이버시 보호형 탐지 기술: 통화 내용(Payload)을 도청하거나 복호화하지 않고, 오직 패킷의 도착 시간 정보(Header Metadata)만을 분석하므로 사용자 개인정보 보호 규정을 준수하면서도 보안을 강화할 수 있는 윤리적 기술 모델을 정립합니다.[12]

---

2. 목표 및 범위

2.1 최종 목표 (Goal)

"오픈 소스 기반의 실시간 패킷 수집 및 하이브리드 머신러닝 분석을 통한 **90%** 이상의 **SIM Box** 탐지 정확도를 갖는 경량화된 보안 시스템 프로토타입 구축"

본 프로젝트는 상용 수준의 대용량 처리(수백만 PPS)보다는 논리적 완결성과 기술적 검증에 초점을 맞춥니다. 3명의 학부생 팀이 **10**주 내에 소화할 수 있도록, 하드웨어 성능 의존도를 낮추고 소프트웨어적인 시뮬레이션과 분석에 집중합니다. 최종적으로는 가상의 사기 트래픽을 생성하고 이를 실시간에 준하는 속도로 탐지하여 대시보드에 시각화하는 전체 파이프라인을 완성하는 것이 목표입니다.[6]

2.2 주요 기능 리스트

본 시스템은 크게 데이터 생성, 수집 및 전처리, AI 탐지, 시각화의 4단계 모듈로 구성됩니다.

모듈명	주요 기능 설명	구현 기술 (예시)

네트워크 시뮬레이터 **(The Generator)**	• 정상 사용자 및 SIM Box 환경의 네트워크 특성(지연, 지터, 패킷 손실) 모사 • 가상 VoIP 트래픽 생성 및 전송	Linux tc-netem, SIPp, GStreamer
패킷 수집 및 파서 **(The Sniffer)**	• Python 기반의 패킷 스니핑 및 RTP 헤더 파싱 • RFC 3550 표준 기반 지터(Jitter) 및 패킷 간 도착 시간(IAT) 계산	Python Scapy, PyShark, Pandas
하이브리드 탐지 엔진 **(The Brain)**	• 특징 엔지니어링: 시계열 통계 추출 (평균, 분산, 버스트 밀도 등) • 앙상블 모델(Random Forest + XGBoost) 기반의 이진 분류 • SMOTE를 활용한 데이터 불균형 해결	Scikit-learn, XGBoost, Imbalanced-learn
통합 관제 대시보드 **(The Dashboard)**	• 탐지된 세션의 위험도 점수(Fraud Score) 표시 • 실시간 지터 변화 그래프 및 패킷 손실률 시각화 • 사기 의심 세션 알림 기능	Streamlit, Plotly

2.3 프로젝트 범위 (In-Scope & Out-of-Scope)

대학생 팀의 역량과 주어진 시간(10주)을 고려하여 프로젝트의 범위를 현실적으로 조정하였습니다.

개발 범위 **(In-Scope):**

1. 가상 데이터셋 구축**:** 실제 통신사 데이터는 보안상 접근이 불가능하므로, 리눅스 네트워크 에뮬레이터(tc netem)를 사용하여 정상 구간과 SIM Box 구간의 네트워크 환경을 가상으로 구축하고, 직접 VoIP 통화를 수행하여 학습용 PCAP 데이터를 생성합니다.[13]

2. **RTP** 헤더 기반 특징 추출**:** 음성 데이터 자체가 아닌, RTP 헤더의 시퀀스 넘버(Sequence Number)와 타임스탬프(Timestamp)만을 활용하여 네트워크 품질 지표를 산출합니다.
3. 오프라인 분석**:** 저장된 PCAP 파일을 분석하는 '파일 기반 모드'를 우선 개발하여 알고리즘의 유효성을 검증합니다.
4. 지도 학습 모델 구현**:** 사기 여부가 라벨링(Labeling)된 데이터셋을 기반으로 Random Forest와 XGBoost 모델을 학습시키고 성능을 비교 평가합니다.[6]

제외 범위 **(Out-of-Scope):**

1. 음성 페이로드 복호화 및 청취**:** 개인정보 보호 및 법적 문제를 피하기 위해 통화 내용을 듣거나 텍스트로 변환(STT)하는 기능은 배제합니다.[1]
2. 레거시 **2G/3G** 신호 분석**:** LTE/VoLTE 환경의 IP 패킷 분석에 집중하며, SS7(Signaling System No. 7)과 같은 구형 회선 교환망 프로토콜은 다루지 않습니다.
3. 고성능 **C++** 최적화**:** 원안의 AF_XDP나 Zero-Copy 같은 커널 레벨의 최적화 기술은 학부생 수준에서 구현 난이도가 지나치게 높으므로, Python 기반의 구현으로 대체하여 알고리즘 논리에 집중합니다.
4. 하드웨어 추적**:** SIM Box 단말기의 물리적 위치 추적이나 제조사 식별(Fingerprinting)은 통신사의 기지국 정보 없이는 불가능하므로 제외합니다.

---

3. 추진 일정 (WBS)

전체 프로젝트 기간은 총 **10**주이며, 각 단계별로 대학생 수준에서 수행 가능한 현실적인 일정을 설정했습니다.

단계 **(Phase)**	기간	주요 마일스톤 및 세부 일정	산출물 **(Deliverables)**
Phase 1: 기획 및 데이터 생성	**1~3**주 **2/1 ~ 2/21**	실험실 구축 및 데이터 확보 • **1**주차**:** 주제 확정, 관련 문헌 조사, 개발 환경(Git, Python, 리눅스 VM) 셋업.[15] • **2**주차**:** 리눅스 tc netem을 활용한 지연/지터 시나리오	• 프로젝트 계획서 • 정상/사기 시나리오별 PCAP 데이터셋

		설계 및 가상 트래픽 생성(SIPp).[13] • **3**주차**:** 파서(Parser) 개발. Scapy를 이용해 PCAP 데이터에서 RTP 헤더 정보를 추출하여 CSV 데이터셋 구축.	
Phase 2: 알고리즘 개발 및 모델링	**4~7**주 **2/22 ~ 3/21**	특징 추출 및 모델 학습 • **4**주차**:** 특징 엔지니어링(Feature Engineering). 지터, IAT 분산 등 AI 학습용 파생 변수 생성.[17] • **5**주차**:** 머신러닝 베이스라인 구축. Scikit-learn 기반 Random Forest 모델 학습.[6] • **6**주차**:** 모델 고도화. XGBoost 도입 및 SMOTE를 활용한 데이터 불균형 해결.[10] • **7**주차**:** 탐지 엔진 통합. 데이터 전처리부터 예측까지 이어지는 자동화 스크립트 완성.	• 특징 추출 스크립트 • 학습된 모델 파일 (.pkl) • 모델 성능 평가 보고서

Phase 3: 시스템 통합 및 완료	**8~10**주 **3/22 ~ 3/31 (4/3)**	대시보드 개발 및 최종 발표 • **8**주차**:** 웹 대시보드 구축. Streamlit을 활용하여 파일 업로드 및 분석 결과 확인 UI 개발.[18] • **9**주차**:** 시스템 통합 테스트. 새로운 테스트 데이터로 전체 파이프라인(파일 업로드->탐지->시각화) 검증 및 디버깅. • **10**주차**:** 바이너리 기반 포스터 형식의 발표자료 제작 & 대본?	• 웹 관제 대시보드 코드 • 최종 완료 보고서 • 시연 영상

---

4. 조직 및 역할 분담

3명의 팀원은 실제 IT 기업의 역할을 분담하여 전문성을 키우되, 10주라는 짧은 기간을 고려하여 긴밀하게 협업합니다.[19]

4.1 팀원별 **R&R (Role & Responsibility)**

1. 네트워크 및 데이터 엔지니어 **(**팀원 **A) :** 이안

- 핵심 역할**:** "데이터 생성 및 환경 관리"
- 상세 업무**:** 리눅스(Ubuntu) 가상 환경 구축, tc netem 기반 네트워크 시뮬레이션, SIPp 트래픽 생성, PCAP 데이터셋 관리 및 CSV 변환 총괄.

2. AI 모델러 및 분석가 **(**팀원 **B) :** 광준

- 핵심 역할**:** "탐지 알고리즘 및 머신러닝 설계"
- 상세 업무**:** 지터 계산 로직 구현, 특징 엔지니어링(Feature Engineering), 머신러닝 모델(RF,

XGBoost) 학습 및 성능 평가, 데이터 불균형 문제 해결.

3. 소프트웨어 및 웹 개발자 **(**팀원 **C) :** 현서

- 핵심 역할**:** "시스템 통합 및 시각화 구현"
- 상세 업무**:** Scapy 기반 파서 모듈 최적화, Streamlit 기반 웹 대시보드 개발, AI 모델 연동 및 전체 코드 통합 관리(Git).

단계	주차	팀원 **A (**데이터**/**인프라**)**	팀원 **B (AI/**분석**)**	팀원 **C (**개발**/**통합**)**
기획 및 데이터 생성	**1**주	주제 확정 및 리눅스 VM 환경 셋업	관련 문헌 조사 및 베이스라인 연구	Git 레포지토리 생성 및 협업 환경 구축
	2주	**tc-netem** 시나리오 설계 & SIPp 트래픽 생성	가짜 데이터(Dummy)로 ML 코드 구조 설계	Scapy/PyShark 라이브러리 테스트 및 환경 설정
	3주	PCAP 데이터 확보 및 CSV 변환 관리	지터**(Jitter)** 계산 로직 연구 및 구현	**Scapy** 기반 **RTP** 헤더 파서 개발 착수
알고리즘 및 모델링	**4** 주	학습 데이터셋 레이블링 및 정제	특징 엔지니어링: 지터, IAT 분산 등 파생 변수 생성	파서 모듈 최적화 및 CSV 자동 추출 스크립트 완성

	5주	추가 사기 시나리오(패킷 손실 등) 데이터 생성	**Random Forest** 베이스라인 모델 학습	데이터 전처리-예측 자동화 파이프라인 설계
	6주	데이터 품질 검증 및 불균형 확인	**XGBoost** 도입 및 **SMOTE**를 이용한 불균형 해결	모델 서빙(Pickle 파일 연동) 테스트
	7주	탐지 엔진 성능 평가용 테스트 세트 준비	모델 성능 평가 보고서 작성 및 최적화	탐지 엔진 통합: 전처리부터 예측까지 자동화 완성
시스템 통합 및 완료	**8**주	전체 인프라 점검 및 최종 데이터 생성	탐지 결과 위험도 점수(Fraud Score) 로직 고도화	**Streamlit** 웹 대시보드 UI 개발 및 시각화 구현
	9주	시스템 통합 테스트 지원 및 버그 리포트	새로운 테스트 데이터로 모델 검증	전체 파이프라인 디버깅 및 사용자 UI 최적화
	10주	최종 보고서 작성 및 데이터 시뮬레이션 검증	모델 분석 결과 및 한계점 정리	시연 영상 제작 및 최종 발표 자료 준비

5. 자원 및 예산

5.1 필요 자원 (하드웨어/소프트웨어)

하드웨어 **(Hardware)**

- 개인 노트북 **3**대**:** 가상머신(VirtualBox 등) 구동 가능한 사양 (RAM 16GB 이상 권장).

소프트웨어 **(Software) -** 전량 오픈 소스

- **OS:** Ubuntu 22.04 LTS (네트워크 에뮬레이션용 필수).
- **Language:** Python 3.8+.
- **Core Libraries:** Scapy, Pandas, Scikit-learn, XGBoost, Streamlit.
- **Simulation Tools:** tc netem, SIPp, Wireshark.

5.2 예산 편성

현금 지출 **'0원'**을 목표로 하는 실무형 Cost-Effective 설계를 유지합니다.

항목	내역	비용
인프라**/SW**	로컬 가상머신 및 오픈 소스 라이브러리 활용	0원
데이터 확보	tc netem을 이용한 자체 합성 데이터 생성	0원
예비비	소액의 클라우드 리소스 사용 등 필요 시	0원
총계		약 **0**원

---

6. 심층 분석 및 기술적 고려사항 (Deep Dive)

6.1 리눅스 기반 지터 시뮬레이션 기술 (tc netem)

10주 내에 성과를 내기 위해 가장 중요한 것은 **2**주차의 데이터 생성 단계입니다. 실제 SIM Box가 유발하는 네트워크 불안정성을 리눅스 명령어 한 줄로 재현할 수 있어야 합니다.[13]

- **SIM Box** 환경 모사 명령어 예시**:**
  sudo tc qdisc add dev eth0 root netem delay 150ms 50ms 25%
  (평균 150ms 지연, ±50ms의 지터, 이전 패킷과의 25% 상관관계 설정)

6.2 Python 기반 지터 계산 핵심 로직

팀원 B와 C는 Scapy로 수집한 패킷에서 타임스탬프를 추출한 뒤, RFC 3550 표준 공식을 사용하여 지터를 수치화해야 합니다.

Python

```python
# 지터 계산 예시 로직
def update_jitter(prev_jitter, current_d):
    return prev_jitter + (abs(current_d) - prev_jitter) / 16.0
```

6.3 10주 완성을 위한 전략

- 병렬화**:** 팀원 A가 데이터를 생성하는 동안 팀원 B는 가짜 데이터(Dummy data)로 ML 코드를 먼저 작성합니다.
- 도구 활용**:** 복잡한 웹 프레임워크 대신 Streamlit을 사용하여 UI 개발 시간을 최소화합니다.[18]

6.4 결론

본 프로젝트는 기존 12주 일정을 대학생 팀의 역량에 맞춰 **핵심 가치(물리적 지표 분석 + ML 탐지)**에 집중한 10주 일정으로 최적화하였습니다. C++ 최적화 등 난도가 높은 부분은 과감히 배제하고 Python 기반의 논리적 검증에 집중함으로써, 짧은 기간 내에도 수준 높은 결과물을 도출할 수 있도록 설계되었습니다.

참고 자료

1. 물리적 계층 아티팩트 분석 및 하이브리드 머신러닝 기반 차세대 SIM Box 탐지 시스템 ...PDF
2. SIMBox Fraud: Challenges and AI-Powered Solutions for Telecom Operators | Subex, 1월 28, 2026에 액세스, https://www.subex.com/blog/simbox-fraud-challenges-and-ai-powered-solutions-for-telecom-operators/
3. Unmasking SIM Box Fraud: A Deep Dive Into Detection Strategies - Oreate AI Blog, 1월 28, 2026에 액세스, https://www.oreateai.com/blog/unmasking-sim-box-fraud-a-deep-dive-into-detection-strategies/63d705ffcf30b0a645f046699d6e994d

4. SigN: SIMBox Activity Detection Through Latency Anomalies at the Cellular Edge - arXiv, 1월 28, 2026에 액세스, https://arxiv.org/html/2502.01193v1
5. Boxed Out: Blocking Cellular Interconnect Bypass Fraud at the Network Edge - USENIX, 1월 28, 2026에 액세스, https://www.usenix.org/system/files/conference/usenixsecurity15/sec15-paper-reaves-boxed.pdf
6. Machine Learning-Based Approach for Identification of SIM Box Bypass Fraud in a Telecom Network Based on CDR Analysis: Case of a Fixed and Mobile Operator in Cameroon - SciRP.org, 1월 28, 2026에 액세스, https://www.scirp.org/journal/paperinformation?paperid=123363
7. Machine Learning-Based Approach for Identification of SIM Box Bypass Fraud in a Telecom Network Based on CDR Analysis: Case of a Fixed and Mobile Operator in Cameroon - ResearchGate, 1월 28, 2026에 액세스, https://www.researchgate.net/publication/368848374_Machine_Learning-Based_Approach_for_Identification_of_SIM_Box_Bypass_Fraud_in_a_Telecom_Network_Based_on_CDR_Analysis_Case_of_a_Fixed_and_Mobile_Operator_in_Cameroon
8. Network packet manipulation in Python, or how to get started with the Scapy library - an interview with Capt. Damian Ząbek, 1월 28, 2026에 액세스, https://ecsc.mil.pl/en/news/network-packet-manipulation-in-python-or-how-to-get-started-with-the-scapy-library-an-interview-with-capt-damian-zabek/
9. Threat Hunting with Pyshark: Using Open Source Python Libraries to Automate Threat Hunting - Insane Cyber, 1월 28, 2026에 액세스, https://insanecyber.com/threat-hunting-with-pyshark/
10. fraud-detection-using-machine-learning/source/notebooks/sagemaker_fraud_detection.ipynb at master - GitHub, 1월 28, 2026에 액세스, https://github.com/awslabs/fraud-detection-using-machine-learning/blob/master/source/notebooks/sagemaker_fraud_detection.ipynb
11. SentryPeerHQ - VoIP fraud detection platform - open source - Elixir Forum, 1월 28, 2026에 액세스, https://elixirforum.com/t/sentrypeerhq-voip-fraud-detection-platform-open-source/56814
12. Detecting VoIP Data Streams: Approaches Using Hidden Representation Learning - AAAI Publications, 1월 28, 2026에 액세스, https://ojs.aaai.org/index.php/AAAI/article/view/26840/26612
13. How to Simulate Network Failures in Linux | by Alexander Zakharenko | Medium, 1월 28, 2026에 액세스, https://medium.com/@zakharenko/how-to-simulate-network-failures-in-linux-b71ab585e86f
14. How can I simulate delayed and dropped packets in Linux? - Pico, 1월 28, 2026에 액세스, https://www.pico.net/kb/how-can-i-simulate-delayed-and-dropped-packets-in-linux/
15. rtpjitterbuffer - GStreamer, 1월 28, 2026에 액세스, https://gstreamer.freedesktop.org/documentation/rtpmanager/rtpjitterbuffer.html
16. sippy/librtpsynth: Low-level library optimized to generate/process sequence of

the RTP packets. - GitHub, 1월 28, 2026에 액세스, https://github.com/sippy/librtpsynth
17. Wireshark: RTP Jitter calculation (Telephony->RTP Stream Analysis) - Seclists.org, 1월 28, 2026에 액세스, https://seclists.org/wireshark/2011/Apr/70
18. SIMBox Fraud Detection in Telecommunication Operators: A Case Study on Djezzy, 1월 28, 2026에 액세스, https://dspace.univ-guelma.dz/jspui/bitstream/123456789/16454/1/F5_8_BOUGUETTOUCHA_AHMED%20RAMI.pdf
19. Three core roles in any ML team and how they collaborate - Qwak, 1월 28, 2026에 액세스, https://www.qwak.com/post/three-core-roles-in-any-ml-team-and-how-they-collaborate
20. Roles on a Machine Learning Project | by James Kotecki - Medium, 1월 28, 2026에 액세스, https://medium.com/machine-learning-in-practice/roles-on-a-machine-learning-project-216903a6dc12
21. Simulating Network Latency, Bandwidth and Packet Loss with a Raspberry Pi - Reddit, 1월 28, 2026에 액세스, https://www.reddit.com/r/RGNets/comments/tspwph/simulating_network_latency_bandwidth_and_packet/